

基于优化的IMU与视觉信息融合

2019年11月23日 14:50



① 基于 Bundle Adjustment 的 VIO 融合

已知:

状态量初始值: 特征点的三维坐标, 相机位置.

系统测量量: 特征点在不同图像上的图像坐标.

Tips: 归一化平面: *ogor*



① 特征点与相机在三维空间中, 可以互相约束 2D 图像坐标形式一个投影平面.

② 空间中的一个点会先投影到归一化平面上, 再经过该相机成像, 从而得到该相机成像的图像坐标.

$$\begin{bmatrix} u \\ v \end{bmatrix} \Rightarrow \begin{bmatrix} x \\ y \end{bmatrix}$$

符号定义: q_i : 相机位置向量. p_i : 主点向量. f_i : 相机焦距.
 c_i : 第 i 个相机. π_i : 投影函数. z_i^c : c_i 对 f_i 的观测.
 z_{ij} : 点 j 的观测 (投影)

解法: 构建误差函数, 利用最小二乘法得到状态量的最优估计.

$$\arg \min_{\mathbf{p}} \sum_i \| \pi(\mathbf{q}_{w_i}, \mathbf{p}_{w_i}, f_i) - \mathbf{z}_{ij}^c \|_{z_{ij}}$$

Input: A vector function $f: \mathcal{R}^m \rightarrow \mathcal{R}^n$ with $n \geq m$, a measurement vector $\mathbf{x} \in \mathcal{R}^n$ and an initial parameters estimate $\mathbf{p}_0 \in \mathcal{R}^m$.

Output: A vector $\mathbf{p}^+ \in \mathcal{R}^m$ minimizing $\|\mathbf{x} - f(\mathbf{p})\|^2$.

Algorithm:

```

k := 0; ν := 2; p := p0;
A := JTJ; cp := x - f(p); g := JTcp;
stop := (||g||∞ ≤ ε1); μ := τ * maxi=1,...,m (Aii);
while (not stop) and (k < kmax)
    k := k + 1;
    repeat
        Solve (A + μI)δp = g;
        if (||δp|| ≤ ε2(||p|| + ε2))
            stop := true;
        else
            pnew := p + δp;
            ρ := (||cp||2 - ||x - f(pnew)||2) / (δpT(μδp + g));
            if ρ > 0
                stop := (||cp|| - ||x - f(pnew)|| < ε4||cp||);
                p = pnew;
                A := JTJ; cp := x - f(p); g := JTcp;
                stop := (stop) or (||g||∞ ≤ ε1);
                μ := μ * max(1/3, 1 - (2ρ - 1)3); ν := 2;
            else
                μ := μ * ν; ν := 2 * ν;
            endif
        endif
    until (ρ > 0) or (stop)
    stop := (||cp|| ≤ ε3);
endwhile
p+ := p;
    
```

Section 2. 最小二乘问题的求解:

假设损失函数 $F(x)$ 是可导且平滑的, 因此, 二阶泰勒展开:

$$F(x+\Delta x) = F(x) + J\Delta x + \frac{1}{2}\Delta x^T H \Delta x + o(\|\Delta x\|^3)$$

其中 J 和 H 为损失函数 F 对变量 x 的一阶导数二阶导矩阵.

当某点处导数为 0, 则该点称为驻点:

此点若 H 为正定矩阵 \rightarrow 局部最小值

负定矩阵 \rightarrow 局部最大值

不定矩阵 \rightarrow 鞍点

Linear Search.

① 最速下降法: 适用于迭代开始阶段:

梯度下降方向为最速下降方向

缺点: 最优解附近收敛较慢

② 牛顿法: 适用于最优解附近

局部

在最优解附近, 如果 $x+\Delta x$ 是最优解, 则损失函数对 Δx 的导数等于 0

$$\frac{\partial}{\partial \Delta x} (F(x) + J\Delta x + \frac{1}{2}\Delta x^T H \Delta x) = J^T + H\Delta x = 0$$

$$\text{即 } \Delta x = -H^{-1}J^T$$

缺点: 二阶导矩阵计算复杂.

③ 阻尼法: Damp Method.

$$F(x+\Delta x) \approx L(\Delta x) = F(x) + J\Delta x + \frac{1}{2}\Delta x^T H \Delta x$$

求以下函数的最小值:

$$\Delta x \equiv \arg \min_{\Delta x} \{ L(\Delta x) + \frac{\mu}{2} \Delta x^T \Delta x \}$$

\hookrightarrow 防止过大步长

其中, $\mu > 0$ 为阻尼因子, $\frac{\mu}{2} \Delta x^T \Delta x = \frac{\mu}{2} \|\Delta x\|_2^2$ 是惩罚项.

对新的损失函数求一阶导, 并令其等于 0, 即

$$L'(\Delta x) + \mu \Delta x = 0$$

$$\Rightarrow J^T + (H + \mu I) \Delta x = 0$$

非线性最小二乘:

残差函数 $f(x)$ 为非线性函数, 对其一阶泰勒近似有:

$$f(x + \Delta x) \approx f(x) + J \Delta x \quad \text{残差函数的一阶近似矩阵}$$

代入损失函数:

$$\begin{aligned} F(x + \Delta x) &\approx L(x) \equiv \frac{1}{2} L'(x) L'(x) \\ &= \frac{1}{2} f^T f + \Delta x^T J^T f + \frac{1}{2} \Delta x^T J^T J \Delta x \\ &= F(x) + \Delta x^T J^T f + \frac{1}{2} \Delta x^T J^T J \Delta x \end{aligned}$$

这样损失函数就近似为一个二次函数, 并且如果雅克比矩阵 J 是满秩的, 若: $x \neq 0 \Rightarrow Jx \neq 0$
则 $J^T J$ 是正定阵, 损失函数有最小值。
 $\Rightarrow (Jx)^T (Jx) > 0$
 $\Rightarrow J^T J$ 是正定矩阵。

另外, 易得: $F'(x) = (J^T f)^T = -b^T$
则: $F'(x) = J^T J$

$$\begin{aligned} F'(x + \Delta x) &= \frac{J^T f}{-b} + J^T J \cdot \Delta x = 0 \\ \Delta x \text{ s.t. } \Delta x_{gn} &= b \end{aligned}$$

令一阶导数为 0, 则有 (Gaussian-Newton)

$$\begin{aligned} J^T f + J^T J \cdot \Delta x &= 0 \\ \underbrace{-b}_{J^T f} + \underbrace{J^T J}_{H} \Delta x &= 0 \\ \Rightarrow H \Delta x_{gn} &= b \Rightarrow \text{normal equation} \end{aligned}$$

The Levenberg-Marquardt Method.

$$(J^T J + \mu I) \Delta x_m = -J^T f \quad \text{with } \mu > 0$$

阻尼因子的作用:

$\mu > 0$, 保证 $(J^T J + \mu I)$ 正定, 迭代朝着下降方向进行。

μ 非常大时, 则 $\Delta x_m = -\frac{1}{\mu} J^T f = -\frac{1}{\mu} F'(x)$ 接近最速梯度

μ 比较小时, 则 $\Delta x_m \approx \Delta x_{gn}$ 接近高斯牛顿法

阻尼因子矩阵补海内迭取:

阻尼因子 μ 大于利用对于 $J^T J$ 的元素信息。半正定的信息矩阵 $J^T J$ 特征值 (入) 和对应特征向量 u_i 。对 $J^T J$ 做特征值分解后有: $J^T J = U \Lambda U^T$, 则:

$$\Delta x_m = -\sum_{j=1}^n \frac{u_j^T F^T}{\lambda_j + \mu} u_j$$

所以一个简单的方法就是:

$$\mu = \begin{cases} \max\{J^T J\} & \text{若 } J^T J \text{ 的某元素大于 } 10^{-8} \\ 1 & \text{否则} \end{cases}$$

点积和最大特征值在一个数量级, 但特征值矩阵 $J^T J$ 并非对称, 因此不能利用对称矩阵的技巧, 最大特征值的数量级在此。
对向量上元素。
一次。

初始值 x_0 与 x^*

收敛

利用维达基, 所有方向上元素都收敛。

阻尼因子 μ 的更新策略

① 定性分析:

- ① 如果 $\Delta x \rightarrow F(x) \uparrow$, 则 $\mu \rightarrow 0$ 止, 增大阻尼减小步长, 拒绝本次迭代
- ② 如果 $\Delta x \rightarrow F(x) \downarrow$, 则 $\mu \rightarrow \Delta x \uparrow$, 减小阻尼增大步长, 加快收敛, 减少迭代次数

② 定量分析:

$$\rho = \frac{F(x) - F(x + \Delta x_{lm})}{L(0) - L(\Delta x_{lm})} = \frac{\text{实际下降}}{\text{近似下降}}$$

$$\begin{aligned} L(0) - L(\Delta x_{lm}) &= -\Delta x_{lm}^T J^T f - \frac{1}{2} \Delta x_{lm}^T J^T J \Delta x_{lm} \\ &\stackrel{b=J^T f}{=} -\frac{1}{2} \Delta x_{lm}^T (-2b + (J^T J + \mu I - \mu I) \Delta x_{lm}) \\ &= \frac{1}{2} \Delta x_{lm}^T (\mu \Delta x_{lm} + b) \end{aligned}$$

若 $\rho < 0$, 则 $F(x) \uparrow$, 应令 $\mu \rightarrow 0$ 止, 增大阻尼, 减小步长.

$\rho > 0$ 且比较大, 减小 μ , 让 LM 接近 GN 更快收敛.

$\rho > 0$ 但比较小, 增大 μ , 缩小迭代步长.

$$\begin{aligned} \text{一种策略: } \rho < 0.25 \quad \mu &= 2\mu \\ \rho > 0.75 \quad \mu &= \mu/3 \end{aligned}$$

Nielsen 策略: (gro, lefos)

if $\rho > 0$

$$\mu := \mu * \max \left\{ \frac{1}{3}, 1 - (2\rho - 1)^3 \right\} \quad U := 2$$

else:

$$\mu := \mu * U \quad U := 2 * U$$

减小了 μ 的振荡.



鲁棒函数拟合 M -Estimator / Robust-estimator.

引言: 最小二乘中遇到 outlier 怎么办?

\Rightarrow **Triggs Correction**

鲁棒拟合函数直接作用在残差 $f_k(x)$ 上, 最小二乘函数如下形式:

$$\min_x \frac{1}{2} \sum \rho(\|f_k(x)\|^2)$$

将误差平方初记作: $S_k = \|f_k(x)\|^2$, 则鲁棒拟合函数可二次泰勒展开:

$$\frac{1}{2} \rho(S) = \frac{1}{2} (c_{const} + \rho' \cdot OS + \frac{1}{2} \rho'' \cdot OS^2)$$

$$\begin{aligned} \Delta S_k &= \|f_k(x + \Delta x)\|^2 - \|f_k(x)\|^2 \\ &\approx \|f_k + J_k \Delta x\|^2 - \|f_k(x)\|^2 \\ &= 2 f_k^T J_k \Delta x + \Delta x^T J_k^T J_k \Delta x \end{aligned}$$

同代有: $\frac{1}{2} p(w) = \frac{1}{2} (const) + \frac{1}{2} p' [2 f_k^T J_k \Delta x + \Delta x^T J_k^T J_k \Delta x]$
 $+ \frac{1}{2} p'' [2 f_k^T J_k \Delta x + (\Delta x)^T J_k^T J_k \Delta x]^2$
 $\approx p' f_k^T J_k \Delta x + \frac{1}{2} p'' \Delta x^T J_k^T J_k \Delta x + p'' (\Delta x)^T J_k^T f_k f_k^T J_k \Delta x + const$
 $= p' f_k^T J_k \Delta x + \frac{1}{2} (\Delta x)^T J_k^T (p' I + 2 p'' f_k f_k^T) J_k \Delta x + const$

对 Δx 求导, 令等于 0, 得到:


$$\sum_k J_k^T (p' I + 2 p'' f_k f_k^T) J_k \Delta x = - \sum_k p' f_k^T J_k$$

$$\sum_k J_k^T W J_k \Delta x = - \sum_k p' f_k^T J_k$$

example: Cauchy loss function:

$p(u) = C^2 \log(C + \frac{C}{u^2})$, 其中 C 为控制参数:

$$p' = \frac{1}{1 + \frac{C}{u^2}} \quad p'' = -\frac{1}{C} (p'(u))^2$$



损失函数控制参数设定:

95% efficiency rule:

如果误差为正态分布:

Huber $C = 1.345$

Cauchy $C = 2.3849 \Leftrightarrow \text{IRLS}$

如果误差非正态分布, 估计误差分布, 然后对误差/估计

median absolute residual 估计.

$$\sigma = 1.482 \text{ med}(C \text{ med}(y - \hat{y}_i))$$